



Tecnológico de Monterrey

Inteligencia artificial avanzada para la ciencia de datos

Reporte

Implementación de un modelo de regresión lineal
mediante Descenso de Gradiente

Mauricio Olguín Sánchez
A01711522

Agosto 2026

Índice general

1. Realizando la implementación «a manita»

- 1.1. Sobre la base de datos seleccionada
- 1.2. Proceso de ETL
 - 1.2.1. *Extraction*
 - 1.2.2. *Transforming*
 - 1.2.3. Sobre los atributos *Month*, *DayofMonth* y *DayOfWeek*
 - 1.2.4. *Loading*
- 1.3. *Exploratory Data Analysis*
 - 1.3.1. Conclusiones
- 1.4. Modelo de regresión lineal sin frameworks
 - 1.4.1. Normalización de los datos
 - 1.4.2. Implementación del modelo
 - 1.4.3. Resultados del modelo

2. Modelo con *frameworks*

3. Anexo

- 3.1. Figuras empleadas

Bibliografía

Capítulo 1

Realizando la implementación «a manita»

1.1. Sobre la base de datos seleccionada

Después de haber investigado en páginas como [UC Irvine](#), [Kaggle](#), el [World Bank Open Data](#), entre otras bases de datos, en la página de [OpenML](#) encontré un *dataset* que se me hizo interesante. Tras aplicar varios filtros, encontré la base de datos [Airlines_DepDelay_10M](#).

Esta base de datos está construida a partir de datos provenientes de la Oficina de Estadísticas de Transporte de los Estados Unidos (*Bureau of Transportation Statistics*, BTS), específicamente, de la base de datos *Airline On-Time Performance Data*. La base de datos seleccionada contiene 10,000,000 de registros y 10 variables, y corresponde a un problema de regresión. A continuación, presento una breve descripción general del *dataset*:

Propósito: Predecir el tiempo de retraso en la salida de los vuelos, medido en minutos (*Departure Delay*).

Fecha de los datos: Desde 1987 hasta 2013.

Formato: ARFF (*Attribute-Relation File Format*).

Tipo de tarea: Regresión.

Número de registros: 10,000,000.

Número de variables: 10.

Aunque OpenML proporciona información sobre cada variable, dentro de la fuente original (en el *Bureau of Transportation Statistics*), existe una descripción más detallada sobre los datos:

DepDelay - numerico. Diferencia, en minutos, entre la hora de salida programada y la hora de salida real del vuelo. Los valores negativos indican que el vuelo salió antes de lo programado.

Month - numerico. Mes en el que se realizó el vuelo, con valores del 1 al 12, donde 1 corresponde a enero y 12 a diciembre.

DayofMonth - numerico. Día del mes en el que se realizó el vuelo, con valores del 1 al 31.

DayOfWeek - numerico. Día de la semana en el que se realizó el vuelo, representado mediante valores del 1 al 7.

CRSDepTime - numerico. Hora de salida programada del vuelo según el sistema de reservas computarizado de la aerolínea (CRS), expresada en hora local con formato HHMM.

CRSArrTime - numerico. Hora de llegada programada del vuelo según el sistema de reservas computarizado de la aerolínea (CRS), expresada en hora local con formato HHMM.

UniqueCarrier - categorico. Código único utilizado para identificar a la aerolínea que opera el vuelo.

Origin - categorico. Código del aeropuerto de origen del vuelo.

Dest - categorico. Código del aeropuerto de destino del vuelo.

Distance - numerico. Distancia total del vuelo, expresada en millas.

1.2. Proceso de ETL

1.2.1. *Extraction*

Como ya lo he mencionado antes, los datos se han obtenido del siguiente link: <https://www.openml.org/search?type=data&status=active&id=42728>

Sin embargo, si se quisiera obtener más datos actuales, habría que descargarlos (sea de forma manual o creando algún *script*) desde el siguiente link: <https://transtats.bts.gov/PREZIP/>.

Aquí, se recopilan todos los datos desde 1987 hasta junio de 2026.

1.2.2. *Transforming*

1.2.3. Sobre los atributos *Month*, *DayofMonth* y *DayOfWeek*

Las variables *Month*, *DayofMonth* y *DayOfWeek*, aunque se encuentran representadas numéricamente en el conjunto de datos, las trataré como variables categóricas. Esto se debe a que, en realidad, los valores numéricos representan categorías y no implican necesariamente una relación lineal entre ellas. Por ejemplo, el mes representado por el valor 12 no debe interpretarse como una categoría doce veces mayor que el mes representado por el valor 1.

Para representar estas variables dentro del modelo de regresión, utilizaré la técnica de *One-Hot Encoding*. Aunque esto implicará

que crezca la dimensionalidad del conjunto de datos.

Por último, debido a que el modelo incorpora un término independiente (*bias*), se descartó una categoría de referencia para cada variable categórica mediante *One-Hot Encoding* con *drop first*. De esta manera se evita introducir una dependencia lineal exacta entre las variables indicadoras y el intercepto del modelo.

En contraste, las variables *UniqueCarrier*, *Origin* y *Dest* son explícitamente categóricas, pero serán excluidas del modelo. Su transformación (utilizando la misma técnica de antes) produciría un incremento considerablemente mayor en la cantidad de variables. Principalmente, tomo esta decisión con el objetivo de mantener un tiempo de ejecución razonable y centrar el proyecto en la implementación manual del algoritmo de regresión.

Sobre los atributos *CRSDepTime* y *CRSArrTime*

Las variables *CRSDepTime* y *CRSArrTime* representan las horas programadas de salida y llegada de los vuelos. En el conjunto de datos original, estas se presentan en formato numérico continuo basado en la estructura HHMM (por ejemplo, las 13:20 se representan como 1320).

Sin embargo, esta representación no es adecuada para ser procesada de forma directa por un modelo de regresión lineal. El formato HHMM introduce discontinuidades matemáticas artificiales debido a los cambios de hora. Por ejemplo, los valores 1059 (10:59) y 1100 (11:00) tienen una separación temporal real de apenas 1 minuto; no obstante, si el modelo consume los datos en su formato original, interpretará una distancia matemática de 41 unidades. Esta magnitud falsa distorsiona los gradientes durante el entrenamiento, asumiendo una separación temporal mucho mayor a la real.

Para corregir este desajuste y linealizar la variable, se transformaron ambos atributos

utilizando como referencia la medianoche absoluta. Para ello, se separaron las horas y los minutos del valor original y se aplicó la siguiente ecuación:

$$\text{Minutos}_{\text{desde la media noche}} = 60 \times \text{Hora} + \text{Minutos}$$

Esta transformación garantiza que, la distancia numérica entre cualquier par de horas, refleja entonces con exactitud la distancia real. 1059 se convierte en 659 y 1100 en 660, logrando la diferencia exacta de 1 unidad. Además, se mantiene la jerarquía de los horarios a lo largo del día en un especto entre 0 a 1439.

Sobre el formato del archivo de los datos

Al empezar a realizar una exploración de los datos, cada vez que tenía que ejecutar el programa para realizar algo, tardaba aproximadamente 45 segundos en sólo cargar los datos. Investigando opciones para solucionar este problema, me encontré con el formato **parquet**. Este formato está precisamente optimizado para mejorar el manejo de datos complejos, el rendimiento de las consultas que se hacen y la eficiencia del almacenamiento [1].

Al informarme que esta integración me resultaría óptima para poder realizar más pruebas más rápidas, la he implementado. Así pues, el archivo ha pasado de tener un peso de 385 MB a sólo 56 MB; además de que el tiempo de carga se redujo drásticamente de 45 segundos a 2 segundos o menos en la carga de datos.

1.2.4. Loading

Una vez hechas las transformaciones anteriores, ahora dividí el tamaño de mi *dataset* en tres principales secciones: *train*, *validation* y *test*. Al ser la cantidad de datos tan alta, podría realizar varias particiones para *validation*, sin embargo, en esta primera

parte en donde me enfoco aprender el algoritmo, sólo haré una vez esta división. Así pues, utilizaré una proporción de 98 % de los datos para *train*, 1 % para *validation* y 1 % para *test*. [2]

1.3. Exploratory Data Analysis

Hice un primer acercamiento general a los datos simplemente realizando un gráfico de pares (*pairplot*), el cual resultó en el siguiente: (ver figura 1.1)




Figura 1.1: *Pair plot* para visualizar la mayoría de los datos comparados entre sí. No se graficaron los 10 millones de puntos por el tiempo de cómputo requerido, sólo se graficaron un millón. Se añadió también que, para cada punto, se etiquetara por su día de la semana (*DayOfTheWeek*) para intentar de visualizar alguna zona de interés así como la distribución de los mismos.


De estos gráficos, se puede observar que, cuando se comparan los datos entre *DepDelay*, se pueden apreciar una posible zona donde la mayoría de los datos recaen, sin embargo, también es interesante ver que existen outliers negativos, es decir, que hubo días en donde un vuelo se adelantó a la hora de su salida. También, podemos observar que entre las variables de *CRSDepTime* y *CRSArrTime* existe una clara agrupación de los datos, por lo que valdría la

pena volver a realizar este gráfico pero ahora también comparándolo con la distancia final y/o con el tiempo de retraso.


Ahora que tenemos el panorama general de los datos, podría pasar a realizar gráficas específicas que me cuenten un poco más sobre los mismos datos. Al contar con los datos de los días de la semana, días del mes, meses del año y las horas en las que se retrasan, decidí hacer un gráfico con los minutos promedio por cada serie de tiempo para ver cómo es que evolucionan los retrasos durante cada periodo de tiempo (ver figura 1.2)



(a) Promedios de retrasos por cada hora.



(b) Promedios de retrasos por cada día de la semana.



(c) Promedios de retrasos por cada mes.

Figura 1.2: Promedios de retrasos por periodos de tiempos.

De cada uno, puedo destacar lo siguiente:

- Para los retrasos por cada hora del día se puede apreciar que, si empezamos a ver la gráfica desde las 5 de la mañana (el punto más bajo en promedio de retrasos), por cada hora que pasa va incrementando el retraso en cada vuelo hasta llegar al punto máximo hasta las 7 de la tarde (19 horas).
- Algo similar a lo anterior pasa a lo largo de la semana pues, a medida que se acerca el fin de semana, los vuelos cada día se retrasan más, hasta que el viernes llega a su punto máximo.
- Por último, durante el verano e inicios de años es cuando existen más retrasos en los vuelos. Aunque esta información me hace pensar que coincide con periodos vacacionales, no puedo afirmar con la información que tengo que esta sea la razón.

Sin embargo, es importante destacar que estos valores podrían estar altamente afectados por los *outliers* que existen para cada serie de tiempo. Para confirmar esto, vale entonces la pena realizar el histograma específico con los retrasos (ver figura 1.3).




Figura 1.3: Histograma con retrasos en los vuelos. **NOTA:** La escala de este histograma se ha recortado de -25 a 150. Esto debido a que los *outliers* (tanto positivos como negativos) son tan grandes y muy pocos que reducen mucho la visibilidad de la gran mayoría de los datos.

Es interesante observar que la inmensa mayoría de vuelos está a tiempo, ya que es en

donde más se concentran los datos. Sin embargo, también es interesante ver que existen vuelos que se adelantan.

Por último, el gráfico más interesante en donde podemos comparar y darnos cuenta de la relación lineal entre las variables es una matriz de correlación (ver figura 1.4)




Figura 1.4: Matriz de correlación.

Como se puede observar en la matriz, existe una correlación lineal débil entre la mayoría de las variables independientes y la variable objetivo *DepDelay*. Las excepciones relativas son *CRSDepTime* y *CRSArrTime*, que presentan los valores positivos más altos (0.12 y 0.11 respectivamente), aunque su poder predictivo lineal sigue siendo moderado[cite: 3]. Asimismo, se detectó una fuerte multicolinealidad (0.70) entre *CRSDepTime* y *CRSArrTime*; un comportamiento estadísticamente esperado dado que representan ventanas temporales lógicamente secuenciales de un mismo vuelo.

1.3.1. Conclusiones

A partir de este análisis, podemos determinar que:

Naturaleza de los datos: La baja correlación generalizada sugiere que la relación que dicta los retrasos no es estrictamente lineal. La baja correlación observada entre las variables predictoras y *DepDelay* sugiere que una parte

importante de la variabilidad de los retrasos podría no ser explicada mediante relaciones lineales simples. Por ello, es razonable esperar que el coeficiente de determinación R^2 obtenido por una regresión lineal sea limitado.

Multicolinealidad temporal: La fuerte relación entre las horas de salida y llegada implica que ambas variables aportan información redundante al modelo, lo cual podría generar cierta inestabilidad al momento de que el algoritmo asigne los pesos.

Disparidad de magnitudes: Las variables independientes operan en escalas drásticamente distintas, contrastando vuelos de miles de millas físicas contra el formato temporal de horas y minutos.

Por estas razones, y para resolver específicamente la diferencia de magnitudes, es indispensable proceder con la normalización de los datos. Este paso asegurará que todas las características numéricas convivan en un rango equitativo. Al nivelar la escala, evitamos que las variables con valores más grandes dominen el cálculo de la función de costo, permitiendo que el algoritmo del *Descenso de Gradiente* converja hacia los pesos óptimos de manera mucho más rápida y estable. En la siguiente sección, hablaré un poco más a detalle sobre los algoritmos que aplicaré sobre mi modelo y su función dentro del mismo.

1.4. Modelo de regresión lineal sin frameworks

1.4.1. Normalización de los datos

El algoritmo a utilizar para la normalización de los datos será *Min-Max*:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Gracias a este algoritmo, lograremos poner en una escala del 0 a 1 todos nuestros datos y, como ya se ha dicho anteriormente, durante la aplicación del *Descenso del Gradiente* converja más rápido.

Hay que tener cuidado a qué variables les aplicamos la normalización de los datos pues no es necesario hacerlo para todas las variables. Además, la normalización se debe de hacer con respecto a los datos de entrenamiento, pero aplicárselo a todos los conjuntos de datos (*test* y *validation*). Como anteriormente he aplicado un *One Hot Encoding* para las variables temporales, entonces, las únicas columnas a las que se les aplicará la normalización serán a *CRSDepTime*, *CRSArrTime* y *Distance*.

1.4.2. Implementación del modelo

Una vez preparados y normalizados los datos, ahora podemos pasar con la implementación del modelo de regresión. El modelo utilizado parte de una combinación lineal de las variables predictoras. Para una observación con n características, la predicción se expresa como:

$$\hat{y} = b + \sum_{j=1}^n w_j x_j \quad (1.1)$$

donde $\hat{y}$ representa la predicción del modelo, b corresponde al *bias* o intercepto, w_j representa el peso asociado a la característica x_j y n corresponde al número total de variables predictoras.

Función de hipótesis

La primera función implementada corresponde a la hipótesis del modelo. Su función es recibir las características de una observación, los pesos actuales y el *bias*, para obtener una predicción.

$$h(x) = b + \sum_{j=1}^n w_j x_j \quad (1.2)$$

Esta función constituye la base del resto de la implementación, ya que tanto el cálculo del error como el cálculo de los gradientes dependen de las predicciones generadas por la hipótesis.

Cálculo del error

Una vez obtenida una predicción, se calcula la diferencia entre el valor predicho y el valor real:

$$e_i = \hat{y}_i - y_i \quad (1.3)$$

El signo del error es importante durante el entrenamiento, ya que posteriormente será utilizado para determinar la dirección en la que deben modificarse los parámetros del modelo.

Función de costo

Para medir qué tan alejadas se encuentran las predicciones respecto a los valores reales se utilizó el error cuadrático medio (*Mean Squared Error*, MSE).

La función de costo utilizada es:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 \quad (1.4)$$

donde m representa el número de observaciones utilizadas para el entrenamiento.

Elevar los errores al cuadrado permite evitar que los errores positivos y negativos se cancelen entre sí y penaliza en mayor medida los errores de mayor magnitud. El objetivo del *Descenso de Gradiente* será entonces encontrar los valores de w y b que minimicen esta función.

Gradiente respecto a los pesos

Para poder modificar los parámetros del modelo es necesario determinar cómo cambia la función de costo cuando se modifica cada uno de los pesos. La derivada parcial del costo respecto a un peso w_j es:

$$\frac{\partial J}{\partial w_j} = \frac{2}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{ij} \quad (1.5)$$

Durante la implementación se recorre cada peso y, para cada uno de ellos, se recorren todas las observaciones del conjunto de entrenamiento. Para cada observación se calcula su predicción, se obtiene su error y posteriormente se multiplica dicho error por el valor correspondiente de la característica. El resultado acumulado representa la dirección y magnitud en la que debe modificarse cada peso para disminuir la función de costo.

Gradiente respecto al *bias*

El *bias* también necesita actualizarse durante el entrenamiento. La derivada de la función de costo respecto al *bias* es:

$$\frac{\partial J}{\partial b} = \frac{2}{m} \sum_{i=1}^m (\hat{y}_i - y_i) \quad (1.6)$$

A diferencia del gradiente de los pesos, en este caso no se multiplica el error por ninguna característica. Esto se debe a que la derivada de la hipótesis respecto al *bias* es igual a 1.

Actualización de los parámetros

Una vez calculados los gradientes, los parámetros del modelo son actualizados mediante el algoritmo de Descenso de Gradiente. La actualización de cada peso se realiza mediante:

$$w_j^{nuevo} = w_j - \alpha \frac{\partial J}{\partial w_j} \quad (1.7)$$

Mientras que el *bias* se actualiza mediante:

$$b^{nuevo} = b - \alpha \frac{\partial J}{\partial b} \quad (1.8)$$

donde α representa la tasa de aprendizaje (*learning rate*).

El signo negativo es fundamental, ya que el

gradiente indica la dirección de mayor incremento de la función de costo. Por lo tanto, se avanza en la dirección contraria para buscar un mínimo de la función.

Proceso de entrenamiento

Las funciones anteriores se integraron en un ciclo de entrenamiento encargado de ajustar progresivamente los parámetros del modelo. Debido a que el conjunto de entrenamiento contiene aproximadamente 9.8 millones de observaciones, no resulta conveniente calcular los gradientes utilizando todos los datos antes de cada actualización, ya que esto incrementaría considerablemente el costo computacional.

Por esta razón, utilicé *Mini-Batch Gradient Descent*, dividiendo el conjunto de entrenamiento en lotes de 2048 observaciones. Esta estrategia permite actualizar los parámetros varias veces durante una misma época, utilizando únicamente una fracción de los datos en cada actualización. De esta forma, se mantiene un balance entre el costo computacional de procesar todos los datos a la vez y la variabilidad que tendría realizar las actualizaciones utilizando una sola observación.

Durante cada época, el conjunto de entrenamiento se recorre por lotes. Para cada uno se realizan las siguientes operaciones:

1. Generar las predicciones utilizando los parámetros actuales.
2. Calcular el error entre las predicciones y los valores reales.
3. Calcular el costo del lote mediante el error cuadrático medio (*MSE*).
4. Obtener el gradiente de cada peso.
5. Obtener el gradiente del *bias*.
6. Actualizar los pesos.
7. Actualizar el *bias*.

Al terminar de procesar todos los lotes, se calcula el costo promedio de la época. Este valor se almacena para posteriormente comparar su evolución con la función de costo del conjunto de validación y observar si el modelo continúa aprendiendo o comienza a perder capacidad de generalización.

Es importante considerar que el valor del MSE se encuentra en una escala diferente a la de la variable objetivo. Debido a que *DepDelay* se mantiene expresada en minutos y el error es elevado al cuadrado. Por esta razón, los valores del MSE pueden parecer elevados sin que esto implique necesariamente que el modelo esté funcionando incorrectamente.

Además, el entrenamiento de este modelo presenta una limitación importante relacionada con la implementación solicitada. Al utilizar operaciones secuenciales y evitar librerías especializadas de álgebra lineal, el costo de ejecutar múltiples configuraciones de hiperparámetros aumenta considerablemente. En un conjunto de 10 millones de observaciones, probar diferentes tasas de aprendizaje, tamaños de lote y cantidades de épocas requeriría numerosas ejecuciones y un tiempo de cómputo elevado. Por ello, en esta primera implementación se priorizó comprender y validar el funcionamiento del algoritmo antes que realizar una búsqueda exhaustiva de hiperparámetros.

Finalmente, también debe considerarse que el modelo utilizado corresponde a una regresión lineal. Este modelo supone que la relación entre las variables predictoras y *DepDelay* puede aproximarse mediante una combinación lineal. Sin embargo, los retrasos de los vuelos pueden depender de múltiples factores y presentar relaciones no lineales que no están representadas en las variables utilizadas. Por lo tanto, incluso con un proceso de optimización correcto, existe un límite en el desempeño que puede alcanzar este modelo y es esperable que permanezca un error residual.

Uso de los conjuntos de entrenamiento, validación y prueba

Para evaluar el comportamiento del modelo se utilizaron tres conjuntos de datos: *train*, *validation* y *test*.

El conjunto de *train* es el único utilizado para modificar los pesos y el *bias*. En cada época, el algoritmo calcula los gradientes a partir de este conjunto y actualiza los parámetros.

El conjunto de *validation* no participa en la actualización de los parámetros. Después de cada época, se utilizan los parámetros obtenidos hasta ese momento para generar predicciones sobre el conjunto de validación y calcular su correspondiente función de costo. Esto permite observar cómo generaliza el modelo sobre datos que no fueron utilizados directamente para actualizar sus parámetros.

Finalmente, el conjunto de *test* se mantiene separado durante el proceso de entrenamiento. Una vez finalizado el entrenamiento, se utilizan los parámetros finales del modelo para generar predicciones sobre este conjunto y obtener una evaluación final del desempeño.

Esta separación permite distinguir entre el desempeño sobre los datos utilizados para aprender y el desempeño sobre datos que el modelo no utilizó para ajustar sus parámetros.

1.4.3. Resultados del modelo

Para el entrenamiento del modelo, utilicé los siguientes parámetros:

- *learning rate* = 0,01
- *epochs* = 10
- *batch size* = 2048

Y, graficando la evolución del MSE por cada época, me resultó en lo siguiente:

El modelo alcanzó un R^2 de X en el conjunto de *train*, valor consistente con la baja correlación lineal observada desde el *EDA* en la




Figura 1.5: Evolución del *Mean Squared Error* por cada época.

matriz de correlación (ver figura 1.4), donde la correlación máxima llegaba a 0.12. Además, podemos observar claramente que tenemos un problema de *underfitting* en nuestro modelo. Esto confirma que la limitación no proviene de un error en el pipeline de datos ni en la implementación del algoritmo, sino de la naturaleza no lineal del fenómeno de retrasos en los vuelvos, que una sola neurona no puede capturar más allá de esta cota.

Capítulo 2

Modelo con *frameworks*

Empezando



Capítulo 3


Anexo


3.1. Figuras empleadas

A continuación, se vuelven a dejar todas las figuras que contienen gráficos en un mayor tamaño poder visualizarlos mejor.









Bibliografía

- [1] Matthew Kosinski Annie Badman. *¿Qué es Apache Parquet? / IBM* — *ibm.com*. <https://www.ibm.com/mx-es/think/topics/parquet>. [Accessed 26-08-2026].
- [2] scgupta. *Training, Validation, and Test Split for ML Models* — *ml4devs.com*. <https://www.ml4devs.com/what-is/train-validation-test-data-split/>. [Accessed 26-08-2026].