

# Reporte de implementación.

Mauricio Olguín Sánchez - A01711522

23 de agosto de 2026

## Índice

### 1. Sobre la base de datos seleccionada

### 2. Proceso de ETL

#### 2.1. *Extraction* . . . . .

## 1. Sobre la base de datos seleccionada

Después de haber investigado en páginas como [UC Irvine](#), [Kaggle](#), el [World Bank Open Data](#), entre otros, encontré en la página de [OpenML](#) un *dataset* interesante. Tras aplicar varios filtros, encontré la base de datos [Airlines\\_DepDelay\\_1M](#). Esta pertenece a la Oficina de Estadísticas de Transporte (*Bureau of Transportation Statistics*) de EE.UU. y, en concreto, es parte de la base de datos de *Airline On-Time Performance Data*.

Dentro del mismo repositorio del *dataset*, se describe lo siguiente del mismo:

**Propósito:** Predecir el tiempo de retraso en la salida de los vuelos (*Departure Delay*).

**Formato:** ARFF (*Attribute-Relation File Format*).

**Tipo de tarea:** Regresión.

Y sobre la descripción de los datos, aunque aquí mismo vienen qué tipo de datos son, rastreando la fuente original de los mismo

(dentro del [Bureau of Transportation Statistics](#)), existe una descripción más profunda sobre los datos:

**DepDelay - numerico.** Diferencia, en minutos, entre la hora de salida programada y la hora de salida real del vuelo. Los valores negativos indican que el vuelo salió antes de lo programado.

**Month - numerico.** Mes en el que se realizó el vuelo, con valores del 1 al 12, donde 1 corresponde a enero y 12 a diciembre.

**DayofMonth - numerico.** Día del mes en el que se realizó el vuelo, con valores del 1 al 31.

**DayOfWeek - numerico.** Día de la semana en el que se realizó el vuelo, representado mediante valores del 1 al 7.

**CRSDepTime - numerico.** Hora de salida programada del vuelo según el sistema de reservas computarizado de la aerolínea (CRS), expresada en hora local con formato HHMM.

**CRSArrTime - numerico.** Hora de llegada programada del vuelo según el sistema de reservas computarizado de la aerolínea (CRS), expresada en hora local con formato HHMM.

**UniqueCarrier - categorico.** Código único utilizado para identificar a la aerolínea que opera el vuelo.

**Origin - categorico.** Código del aeropuerto de origen del vuelo.

**Dest - categorico.** Código del aeropuerto de destino del vuelo.

**Distance - numerico.** Distancia total del vuelo, expresada en millas.

## 2. Proceso de ETL

### 2.1. *Extraction*

Como ya lo he mencionado antes, los datos se han obtenido del siguiente link: [https://www.openml.org/search?type=data&sort=qualities.NumberOfInstances&status=active&qualities.NumberOfClasses=lte\\_1&order=desc&qualities.NumberOfInstances=between\\_100000\\_1000000&id=42721](https://www.openml.org/search?type=data&sort=qualities.NumberOfInstances&status=active&qualities.NumberOfClasses=lte_1&order=desc&qualities.NumberOfInstances=between_100000_1000000&id=42721)